

1. SLIDE 1: Pendahuluan / Latar Belakang

Tingginya transaksi di platform Shopee menghasilkan ledakan data ulasan produk yang merupakan representasi langsung dari suara konsumen. Namun, **rating bintang bersifat ambigu** karena tidak mampu menjelaskan aspek spesifik apa yang membuat konsumen puas atau kecewa. Nilai informasi terdalem justru terkunci di dalam **teks ulasan yang sifatnya tidak terstruktur**.

Analisis secara manual tidak mungkin dilakukan akibat volume ulasan yang masif. Tantangan ini diperparah oleh **karakteristik teks ulasan Shopee yang sangat informal**, penuh singkatan, kata tidak baku, emoji, dan percampuran bahasa. Kondisi ini menuntut sebuah pendekatan sistematis agar potensi data berharga tersebut tidak terbuang sia-sia.

Untuk menjawab persoalan tersebut, penelitian ini mengintegrasikan **analisis sentimen dengan aspect tagging** guna mentransformasi data teks tidak terstruktur menjadi informasi yang terstruktur. Studi kasus difokuskan pada **satu toko dengan lima produk terlaris** untuk menghasilkan temuan mendalam yang dapat ditindaklanjuti secara tepat sasaran oleh pelaku bisnis.

2. SLIDE 2: Rumusan Masalah dan Tujuan

1. Bagaimana menerapkan tahapan pra-pemrosesan yang sesuai dengan karakteristik bahasa informal ulasan Shopee, seperti kata tidak baku, perpanjangan huruf, dan emoji, agar teks siap dianalisis?
2. Bagaimana kinerja model Support Vector Machine (SVM) dengan ekstraksi fitur TF-IDF dalam mengklasifikasikan sentimen ulasan ke dalam tiga kelas, yaitu positif, negatif, dan netral?
3. Aspek-aspek apa saja yang paling sering dikeluhkan konsumen pada ulasan bersentimen negatif dan berbintang tiga, ditinjau dari kualitas barang, kemasan, dan pengiriman?

3. Tinjauan Pustaka / Studi Terkait (TIDAK MASUK PPT)

4. SLIDE 3: Rencana Pengumpulan Data

● Sumber Data & Antisipasi Ketidakseimbangan

Penelitian menggabungkan dua sumber data: **ulasan riil dari 5 produk terlaris toko target** sebagai objek analisis utama, dan **dataset publik (Kaggle)** sebagai pemer kaya data latih. Dataset publik dipilih dari kategori sejenis untuk meminimalkan *domain mismatch*, sekaligus mengantisipasi **ketidakseimbangan kelas (class imbalance)** mengingat ulasan pada produk terlaris umumnya didominasi rating positif sehingga contoh kelas negatif dan netral cenderung langka.

● Teknik Akuisisi Data (Web Scraping)


Pengumpulan data dari toko target dilakukan melalui teknik *web scraping* menggunakan **pustaka Playwright**, karena konten Shopee dimuat secara dinamis melalui JavaScript dan tidak menyediakan API publik. Proses pengikisan data dirancang secara bertanggung jawab menggunakan **jeda**

waktu acak (*randomized delay*) untuk menjaga stabilitas sistem, meniru pola akses manusia, dan menghindari pembebanan berlebih pada server platform.

- **Pertimbangan Legal & Etika**

Guna memitigasi risiko terkait ketentuan layanan (*Terms of Service*) platform, pengambilan data **dibatasi pada volume wajar** dan fokus pada konten ulasan serta rating saja. Penelitian ini **mengabaikan informasi pribadi (privasi) pengguna** dan seluruh data dimanfaatkan murni untuk keperluan akademik non-komersial. Seluruh batasan dan risiko teknis ini juga dicatat secara eksplisit pada bab Risiko dan Mitigasi.

5. SLIDE 4: PIPELINE



6. SLIDE 5: Rencana Pra-pemrosesan Data

● Pembersihan Awal & Arsitektur Dual-Track Preprocessing

Teks ulasan mentah dibersihkan melalui *case folding*, penanganan *elongation*, konversi emoji ke teks, kamus *slang*, dan *bilingual mapping*. Data kemudian dialirkan ke dalam dua jalur terpisah: **Jalur Berat** (tokenisasi, *stopword removal*, *stemming* Sastrawi) untuk memadatkan dimensi fitur TF-IDF dan SVM, serta **Jalur Ringan** (tanpa *stemming* dan *stopword* agresif) untuk menjaga keutuhan struktur kata kunci aspek keluhan agar dapat terdeteksi secara akurat oleh ekspresi reguler (Regex).

- **Strategi Pelabelan Hibrida & Fokus Bintang 3**

Pelabelan sentimen menggunakan pendekatan hibrida yang memadukan otomatisasi rating bintang dengan **verifikasi manual**. Langkah verifikasi manual ini difokuskan secara khusus pada **ulasan bintang 3** yang memiliki tingkat ambiguitas tinggi (campuran pujian dan keluhan) guna meminimalkan kesalahan label otomatis. Sistem juga menerapkan aturan operasional kaku untuk menangani kasus tepi (*edge cases*) seperti ulasan satu kata atau teks yang hanya berisi emoji.

- **Mitigasi Ketidakseimbangan Data & Evaluasi Model**

Kondisi ketidakseimbangan kelas (*class imbalance*) akibat dominasi sentimen positif diantisipasi melalui **penambahan contoh kelas minoritas (negatif dan netral) yang disuntikkan dari dataset publik**. Guna menjamin penilaian performa model yang adil dan objektif di tengah ketidakseimbangan data ini, metrik evaluasi tidak bertumpu pada akurasi semata, melainkan diukur secara komprehensif menggunakan ***Precision, Recall, dan F1-score***.

7. SLIDE 6: Rencana Pemodelan

- **Ekstraksi Fitur TF-IDF & Klasifikasi Sentimen SVM**

Teks dari Jalur Berat ditransformasikan menjadi representasi numerik menggunakan **TF-IDF dengan kombinasi Unigram dan Bigram** guna menangkap frasa bermuatan sentimen secara utuh. *Vocabulary* TF-IDF dibangun dari penggabungan data toko target dan dataset publik untuk mencegah *domain mismatch*. Klasifikasi ke dalam tiga kelas sentimen (Positif, Negatif, Netral) dieksekusi menggunakan algoritma **Support Vector Machine (SVM)** karena keandalannya pada ruang fitur teks yang berdimensi tinggi dan efisiensi komputasinya dibandingkan model *deep learning*.

- **Mekanisme Gerbang Penyaringan (The Gatekeeper)**

Sistem menerapkan dependensi urutan yang kaku di mana proses klasifikasi SVM harus diselesaikan terlebih dahulu sebagai basis penyaringan sekuensial. Gerbang ini secara khusus menyaring **ulasan yang diprediksi bersentimen negatif oleh model SVM serta ulasan yang memiliki rating bintang 3**. Strategi ini menjamin sistem tetap mampu menangkap ulasan anomali (rating bintang tinggi namun teksnya berisi keluhan nyata), sekaligus mengeliminasi ulasan positif dari tahapan analisis berikutnya demi efisiensi penambahan keluhan.

- **Penandaan Aspek Regex & Skema Validasi Data**

Ulasan hasil saringan (menggunakan representasi teks Jalur Ringan) dipetakan menggunakan **pendekatan berbasis aturan (*rule-based*) melalui Ekspresi Reguler (Regex)** untuk mengelompokkan keluhan ke dalam aspek kualitas barang, kemasan, dan pengiriman secara transparan sesuai bentuk kata pasca-normalisasi. Untuk pengujian, pembagian data menggunakan skema ***Stratified Split yang diperkuat dengan Validasi Silang (Cross-Validation)***, di mana sebagian data toko target terlabel disuntikkan ke dalam data latih publik agar model adaptif terhadap karakteristik domain toko target.

8. SLIDE 7: Rencana Evaluasi

- **Evaluasi Klasifikasi Sentimen & Metrik Makro (SVM)**

Kinerja klasifikasi sentimen diukur secara kuantitatif menggunakan metrik **Precision, Recall, dan F1-score**, dengan secara sengaja menghindari akurasi untuk mencegah hasil yang menyesatkan akibat dominasi kelas positif (*class imbalance*). Penilaian dilaporkan per kelas dan disimpulkan menggunakan **Macro-Average F1-score** untuk memberikan bobot setara pada kelas minoritas (negatif dan netral). Selain itu, **Confusion Matrix** digunakan secara transparan untuk memvisualisasikan pola kesalahan klasifikasi model, terutama pada kelas netral dari ulasan bintang 3 yang memiliki tingkat ambiguitas tinggi.

- **Evaluasi Penandaan Aspek & Kriteria Keberhasilan Sistem**

Berbeda dengan komponen pembelajaran mesin, penandaan aspek berbasis aturan dievaluasi secara kualitatif melalui **pemeriksaan manual pada sampel ulasan**. Evaluasi ini bertujuan menguji ketepatan pola ekspresi reguler (Regex) dalam memetakan aspek keluhan tanpa ada pola yang terlewat atau salah tertandai. Penelitian ini menetapkan kriteria keberhasilan dari dua sisi: pencapaian nilai **Macro F1-score yang memadai** dalam mengenali kelas minoritas, serta kemampuan sistem dalam menghasilkan **pemetaan aspek keluhan yang jelas dan dapat ditindaklanjuti** dari ulasan negatif dan bintang 3 demi memberikan rekomendasi yang bermanfaat bagi pelaku bisnis.

9. Rencana Visualisasi dan Pelaporan Hasil (TIDAK MASUK PPT)

10. SLIDE 8: Tools dan Teknologi

- **Lingkungan, Akuisisi, dan Manajemen Data**

Seluruh rangkaian *pipeline* penelitian dibangun secara terpadu menggunakan bahasa pemrograman **Python** guna menjaga konsistensi integrasi sistem. Pengumpulan data ulasan dinamis Shopee dieksekusi menggunakan pustaka **Playwright** yang dilengkapi jeda waktu acak (*randomized delay*), sementara manipulasi, penggabungan data dua sumber, serta pengelolaan struktur data tabular dikelola secara efisien melalui pustaka **pandas**.

- **Pra-pemrosesan Teks dan Penandaan Aspek**

Tahap pembersihan komponen teks memanfaatkan kombinasi beberapa pustaka khusus: **Sastrawi** untuk pengakaran (*stemming*) dan penghapusan *stopword* bahasa Indonesia, pustaka **emoji** untuk konversi simbol ke teks, **kamus slang** dari repositori terbuka untuk normalisasi kata tidak baku, serta leksikon **InSet** untuk pemetaan makna teks dwibahasa. Selanjutnya, pemetaan kluster keluhan dijalankan secara transparan melalui pendekatan berbasis aturan memanfaatkan modul bawaan RE (**Regular Expression**).

- **Pemodelan, Evaluasi, dan Visualisasi**

Tahap ekstraksi fitur TF-IDF (Unigram & Bigram), pembagian data, validasi silang, hingga pemodelan klasifikasi sentimen menggunakan **Support Vector Machine (SVM)** seluruhnya dibangun di atas pustaka **scikit-learn**. Pustaka

scikit-learn juga menangani kalkulasi metrik evaluasi numerik beserta *confusion matrix*, yang kemudian disajikan secara visual menggunakan **matplotlib** dan **seaborn**, dilengkapi dengan **wordcloud** untuk menonjolkan kata kunci keluhan dominan, serta **Streamlit** (opsional) sebagai *dashboard* hasil analisis yang interaktif.

11. Timeline dan Milestone

(LAGI DIBUAT FILE GANTT CHARTNYA, TAPI NGGA TAU BAKAL SELESAI ATAU KAGA AWOWKOWKWOK)

12. SLIDE 9: Risiko dan Mitigasi

- **Risiko & Mitigasi Pengumpulan Serta Kualitas Data**

Proses *scraping* memiliki risiko pemblokiran oleh sistem anti-bot Shopee dan kendala ketentuan layanan (*Terms of Service*). Risiko ini dimitigasi melalui penerapan **jeda waktu acak (*randomized delay*)**, batasan volume wajar, serta penyiapan dataset publik sebagai cadangan (*fallback*). Sementara itu, risiko **ketidakseimbangan kelas (*class imbalance*)** dan ambiguitas ulasan bintang 3 diatasi dengan menyuntikkan data minoritas dari dataset publik serta menerapkan **pelabelan hibrida berbasis aturan operasional yang baku** untuk meminimalkan subjektivitas pada kasus tepi (*edge cases*).

- **Risiko & Mitigasi Pemodelan (SVM & Regex)**

Tahap pemodelan menghadapi risiko ***domain mismatch*** dan penurunan performa model pada kelas netral. Strategi mitigasinya adalah menerapkan ***Vocabulary Fusion*** pada TF-IDF serta **penyuntikan data lokal terlabel**, sedangkan kelemahan model dipetakan secara transparan menggunakan *confusion matrix*. Untuk mengantisipasi risiko kegagalan Regex dalam menangkap aspek keluhan akibat variasi kata, pola ekspresi reguler dirancang khusus **mencocokkan teks pasca-normalisasi slang** dan keandalannya diuji ulang melalui evaluasi manual pada sampel ulasan.