

📁 Studi Kasus: Toko Forebie di Shopee

Analisis Sentimen Ulasan Toko Forebie di Shopee

Mengklasifikasikan sentimen 684 ulasan pelanggan menggunakan representasi fitur TF-IDF dan perbandingan tiga algoritma klasifikasi — Support Vector Machine, Naive Bayes, dan Logistic Regression — untuk mengidentifikasi model yang paling efektif pada ulasan e-commerce berbahasa Indonesia.

Mata Kuliah Sains Data

Program Studi Teknik Informatika

Fakultas Sains dan Teknologi, UIN Syarif Hidayatullah Jakarta

— TIM PENELITIAN

Anggota **Kelompok 4**

Mahasiswa Program Studi Teknik Informatika
Universitas Islam Negeri Syarif Hidayatullah Jakarta



Mayra Aldisya Asmoro

11230910000059



Dewi Saidah Ahmad

11230910000095



Lindan Akbar

11230910000097

— LATAR BELAKANG

Ulasan pelanggan sebagai sumber data strategis

Shopee merupakan salah satu platform e-commerce terbesar di Asia Tenggara dengan ratusan juta kunjungan bulanan. Setiap toko memiliki ratusan hingga ribuan ulasan yang berisi feedback berharga, namun volume yang besar membuat analisis manual tidak lagi efisien. Diperlukan pendekatan otomatis berbasis NLP dan machine learning.

100jt+

Kunjungan Shopee per bulan di Indonesia

684

Ulasan yang berhasil dikumpulkan

10

Produk kosmetik Forebie



Mengapa Forebie? Toko kosmetik ini dipilih karena memiliki variasi ulasan yang beragam — mulai dari keluhan efek samping skincare hingga pujian kecocokan produk di kulit. Domain kosmetik juga menantang dari perspektif NLP karena ulasan cenderung menggunakan bahasa informal, slang, dan emoji secara intensif, sehingga menuntut preprocessing yang lebih cermat.

— TUJUAN PENELITIAN

Apa yang ingin **dicapai?**



Pengumpulan Data Primer

Mengumpulkan ulasan langsung dari halaman produk Shopee menggunakan teknik web scraping berbasis Playwright. Data primer memastikan ulasan yang dianalisis benar-benar berasal dari pelanggan toko, bukan dari platform review pihak ketiga.



Text Preprocessing

Melakukan pra-pemrosesan teks yang mempertimbangkan karakteristik unik ulasan e-commerce berbahasa Indonesia — termasuk konversi emoji, penanganan bahasa informal, penghapusan stopwords dengan pengecualian kata negasi, dan stemming menggunakan Sastrawi.



Perbandingan 3 Algoritma

Membangun dan membandingkan tiga model klasifikasi sentimen — SVM (LinearSVC), Naive Bayes (MultinomialNB), dan Logistic Regression — untuk menentukan algoritma yang paling efektif dalam mengklasifikasikan sentimen ulasan pada domain kosmetik.



Evaluasi dengan Metrik yang Tepat

Menggunakan F1-Score weighted sebagai metrik utama, bukan hanya akurasi, karena dataset memiliki distribusi kelas yang tidak seimbang. Ini memastikan evaluasi yang lebih fair terhadap performa model pada setiap kelas sentimen.

— ALUR KERJA

Pipeline **End-to-End**

Seluruh proses dilakukan secara sistematis — dari pengumpulan data mentah di Shopee hingga menghasilkan model klasifikasi sentimen yang siap digunakan untuk prediksi.



Seluruh pipeline diimplementasikan menggunakan Python dengan library utama: **Playwright** untuk scraping, **Sastrawi** untuk stemming Bahasa Indonesia, dan **scikit-learn** untuk TF-IDF, modeling, serta evaluasi. Model terbaik disimpan dalam format `.joblib` untuk penggunaan prediksi di masa mendatang.

— PENGUMPULAN DATA

684 ulasan dari 10 produk Forebie

Data dikumpulkan langsung dari halaman ulasan produk toko Forebie di Shopee menggunakan **Playwright** — sebuah framework browser automation yang mampu mensimulasikan interaksi pengguna nyata. Pendekatan ini diperlukan karena Shopee menggunakan proteksi DOM dinamis yang tidak dapat diakses oleh scraper berbasis HTTP biasa.



Navigasi otomatis ke halaman produk dan bagian ulasan



Injeksi JavaScript untuk filter rating bintang 1–5 secara terpisah



Ekstraksi ID komentar, username, rating, dan teks ulasan



Mode incremental untuk menambah data tanpa duplikasi

STRUKTUR DATA AWAL

Dataset mentah terdiri dari **684 ulasan** dengan 5 kolom utama. Melalui proses feature engineering, ditambahkan 4 kolom baru termasuk label sentimen yang diturunkan dari rating.

id_komentar

produk_url

username

rating

ulasan

PELABELAN SENTIMEN

Rating digunakan sebagai proxy sentimen:

★ 1-2 → Negatif | ★ 3 → Netral | ★ 4-5 → Positif

— TEXT PREPROCESSING

Data mentah perlu melalui 8 tahap preprocessing

Setiap tahap dirancang untuk menghilangkan noise dan menormalisasi teks agar model dapat memproses data secara optimal. Urutan tahapan ini berpengaruh terhadap kualitas hasil akhir.

1 Hapus missing values — baris dengan kolom ulasan kosong dihilangkan dari dataset

2 Hapus outlier — ulasan dengan >150 kata dihapus karena umumnya berisi spam atau narasi yang tidak representatif

3 Case folding — seluruh teks dikonversi ke huruf kecil untuk konsistensi (contoh: "BAGUS" → "bagus")

4 Konversi emoji ke teks — menggunakan library `emoji` dengan parameter bahasa Indonesia untuk mempertahankan informasi emosional

5 Hapus noise — URL, mention, angka, dan tanda baca dihilangkan menggunakan regex

6 Stopword removal — kata tidak informatif dihapus, namun kata negasi ("tidak", "kurang", "belum") **tetap dipertahankan**

7 Stemming — kata berimbuhan diubah ke bentuk dasar menggunakan Sastrawi (contoh: "berlari" → "lari")

8 Label encoding — label sentimen dikonversi ke numerik: Negatif=0, Netral=1, Positif=2



Mengapa kata negasi dipertahankan? Dalam analisis sentimen, kata negasi mengubah polaritas kalimat secara fundamental. Jika kata "tidak" dihapus, frasa "tidak bagus" menjadi "bagus" — mengubah sentimen negatif menjadi positif. Setelah seluruh preprocessing, dataset akhir terdiri dari **666 ulasan bersih**.

— PROFIL DATA

Distribusi sentimen: didominasi ulasan positif

Dataset final terdiri dari **666 ulasan bersih** dengan distribusi kelas yang tidak seimbang (imbalanced). Pola ini umum ditemukan pada dataset e-commerce — mayoritas pelanggan cenderung memberikan ulasan positif.

• Positif

62%

• Netral

20%

• Negatif

18%



Class Imbalance

Ulasan positif **3x lebih banyak** dari negatif. Tanpa penanganan, model akan cenderung bias terhadap kelas mayoritas — memprediksi "Positif" untuk hampir semua input.

Solusi: Parameter `class_weight='balanced'` diterapkan pada SVM dan Logistic Regression. Parameter ini otomatis menyesuaikan bobot kelas berdasarkan frekuensi, sehingga kelas minoritas mendapat penalti lebih besar saat salah prediksi.

TF-IDF + 3 Algoritma Klasifikasi

Teks yang sudah bersih direpresentasikan sebagai vektor numerik menggunakan TF-IDF, kemudian tiga algoritma klasifikasi dibandingkan untuk menemukan model yang paling efektif.



TF-IDF (Term Frequency–Inverse Document Frequency)

Model machine learning memerlukan input numerik, sehingga teks perlu dikonversi menjadi representasi vektor. TF-IDF mengukur seberapa penting sebuah kata dalam suatu dokumen relatif terhadap seluruh korpus — kata yang sering muncul di satu ulasan tapi jarang di ulasan lain mendapat bobot tinggi.

- `max_features=5000` — membatasi dimensi fitur
- `ngram_range=(1,2)` — unigram + bigram untuk menangkap frasa seperti "tidak cocok"
- `min_df=2, max_df=0.95` — filter kata terlalu jarang atau terlalu umum



SVM (LinearSVC)

Mencari hyperplane pemisah antar kelas dengan margin terlebar. Efektif untuk data berdimensi tinggi seperti vektor TF-IDF. Menggunakan

```
class_weight='balanced'
```



Naive Bayes (MultinomialNB)

Algoritma probabilistik berbasis teorema Bayes yang menghitung peluang sebuah dokumen termasuk dalam kategori tertentu berdasarkan distribusi kata. Menggunakan parameter smoothing `alpha=1.0`.



Logistic Regression

Model probabilistik yang menghitung peluang kelas menggunakan fungsi sigmoid. Menghasilkan probabilitas untuk setiap kelas, memudahkan interpretasi. Menggunakan `class_weight='balanced'` dan `max_iter=1000`.

— HASIL

Model dengan performa terbaik



Logistic Regression

0.732

F1-SCORE (WEIGHTED)

73.1%

ACCURACY

Dataset dibagi 80% training dan 20% testing dengan stratified split. Berikut perbandingan performa ketiga model berdasarkan F1-Score weighted — metrik yang lebih representatif dibanding akurasi untuk dataset imbalanced.

Logistic Regression

F1: 0.732

#1

SVM (LinearSVC)

F1: 0.717

#2

Naive Bayes

F1: 0.685

#3

— DETAIL PERFORMA

Classification Report

per kategori sentimen

Performa Logistic Regression bervariasi antar kelas. Kelas Positif sebagai mayoritas menunjukkan performa terbaik, sementara kelas Netral menjadi yang paling menantang — konsisten dengan temuan di berbagai penelitian analisis sentimen.

POSITIF**0.82****F1-Score**

Precision: 0.88 · Recall: 0.78

83 sampel uji

Performa tertinggi

NEGATIF**0.71****F1-Score**

Precision: 0.60 · Recall: 0.88

24 sampel uji

Recall tinggi (88%)

NETRAL**0.46****F1-Score**

Precision: 0.50 · Recall: 0.36

27 sampel uji

Kelas paling sulit



Mengapa kelas Netral sulit? Ulasan netral secara linguistik cenderung ambigu — sering berisi campuran pujian dan kritik dalam satu kalimat, atau hanya bersifat deskriptif tanpa ekspresi emosi yang jelas. Temuan ini konsisten dengan penelitian Kadir & Fairuzabadi [5] yang juga melaporkan F1 terendah pada kelas Netral (hanya 0.14).

— TEMUAN UNIK

Anomali pada data ulasan negatif

Analisis Word Cloud pada ulasan negatif mengungkapkan dua fenomena menarik yang jarang dibahas dalam literatur analisis sentimen e-commerce. Kedua temuan ini berimplikasi penting terhadap kualitas data dan performa model.



Kontaminasi dari Balasan Penjual (Seller Reply Leakage)

Kata-kata seperti **"mohon"**, **"maaf"**, **"minbie"**, **"bantu"** mendominasi Word Cloud ulasan negatif. Setelah investigasi, ditemukan bahwa web scraper turut mengekstrak teks **balasan admin toko** yang melekat pada ulasan pelanggan. Admin Forebie ("Minbie") secara konsisten membalas ulasan bintang 1-2 dengan template yang sama, sehingga kata-kata dari balasan ini mencemari distribusi kata pada data negatif.

"Mohon maaf kak, apakah ada kendala? Minbie siap membantu" — template balasan admin toko Forebie yang muncul pada hampir semua ulasan negatif



Artefak Translasi Emoji

Proses konversi emoji ke teks Indonesia menggunakan `emoji.demojize(language="id")` menghasilkan kata-kata yang menyesatkan setelah tahap stemming. Kata-kata hasil translasi emoji dipecah menjadi token individual yang kehilangan makna aslinya, memunculkan noise pada fitur teks.

Hati bersinar: "hati_bersinar" → token "hati" + "sinar"

Wajah menangis: "wajah_menangis_keras" → token "wajah" + "menang" + "keras"

— PERBANDINGAN

Posisi penelitian ini terhadap studi sejenis

Meskipun akurasi headline lebih rendah dibanding beberapa penelitian sebelumnya, weighted F1-Score menunjukkan bahwa model ini lebih seimbang dalam mengenali ketiga kelas sentimen.

ASPEK	KADIR & FAIRUZABADI [5]	SAEPUDIN ET AL. [6]	FATHURROHMAN ET AL. [7]	PENELITIAN INI
Platform	Shopee (Google Play)	Shopee (Google Play)	Shopee Xpress	Shopee (Toko Forebie)
Jumlah Data	5.000	3.000	497	684
Pelabelan	Rating	TextBlob (otomatis)	Manual	Rating
Model Terbaik	LR (85,11%)	Random Forest (94%)	SVM (93%)	LR (73,1%)
F1-Score	macro: 0,58	—	—	weighted: 0,732



Meskipun akurasi headline lebih rendah, weighted F1-Score (0,732) lebih tinggi dari macro-F1 penelitian [5] (0,58). Perbedaan ini karena: (1) klasifikasi 3 kelas secara inheren lebih sulit dari biner, (2) dataset lebih kecil (684 vs 5.000), (3) domain kosmetik menggunakan bahasa informal dan emoji intensif. Model ini lebih seimbang — tidak hanya mengandalkan prediksi kelas mayoritas.

— ANALISIS

Mengapa **Logistic Regression** unggul?

Keunggulan Logistic Regression pada dataset ini konsisten dengan temuan Kadir & Fairuzabadi [5] yang juga melaporkan LR sebagai model terbaik untuk analisis sentimen ulasan Shopee. Terdapat tiga faktor utama yang menjelaskan hal ini.



Estimasi Probabilistik

Logistic Regression menghasilkan probabilitas kelas untuk setiap prediksi, memungkinkan decision boundary yang lebih halus dan nuanced. Berbeda dengan SVM yang hanya menentukan sisi mana dari hyperplane sebuah data berada, LR memberikan tingkat "keyakinan" untuk setiap kelas.



Kompatibel dengan Class Weight

Parameter `class_weight='balanced'` bekerja lebih efektif pada Logistic Regression karena langsung mempengaruhi fungsi loss secara proporsional. Kelas minoritas mendapat penalti yang lebih besar saat salah diprediksi, mendorong model untuk lebih "memperhatikan" kelas Negatif dan Netral.



Stabil pada Data Terbatas

Dengan hanya 666 sampel, Logistic Regression menunjukkan performa yang lebih stabil dibandingkan SVM yang cenderung lebih sensitif terhadap ukuran dataset. LR juga lebih tahan terhadap overfitting pada dataset kecil berkat regularisasi yang terintegrasi secara default.



Temuan ini sejalan dengan literatur yang menunjukkan bahwa Logistic Regression secara konsisten menjadi pilihan yang kompetitif untuk klasifikasi teks, terutama ketika dikombinasikan dengan representasi fitur TF-IDF dan penanganan class imbalance yang tepat.

— KESIMPULAN

Ringkasan **temuan utama**



Pipeline End-to-End Berhasil Dibangun

Sistem lengkap dari pengumpulan data primer menggunakan Playwright, feature engineering, preprocessing teks dengan Sastrawi, ekstraksi fitur TF-IDF, hingga pemodelan dan evaluasi — berhasil diimplementasikan dan menghasilkan model yang siap digunakan untuk prediksi sentimen.



Logistic Regression sebagai Model Terbaik

Dari perbandingan tiga algoritma, Logistic Regression memberikan performa terbaik dengan F1-Score weighted 0,732 dan akurasi 73,1%. Model ini paling seimbang dalam mengenali ketiga kelas sentimen, mengungguli SVM (F1: 0,717) dan Naive Bayes (F1: 0,685).



Performa Kompetitif terhadap Studi Sejenis

Weighted F1-Score (0,732) lebih tinggi dari macro-F1 yang dilaporkan penelitian [5] (0,58), meskipun akurasi headline lebih rendah. Ini menunjukkan model lebih seimbang dan tidak hanya bergantung pada prediksi kelas mayoritas.



Temuan Unik Teridentifikasi

Kontaminasi data dari balasan penjual (seller reply leakage) dan artefak translasi emoji merupakan temuan yang jarang dibahas dalam literatur, namun berpotensi signifikan mempengaruhi kualitas analisis sentimen pada ulasan e-commerce.

Rekomendasi untuk penelitian selanjutnya

Berdasarkan temuan dan keterbatasan penelitian ini, terdapat beberapa area yang dapat dikembangkan untuk meningkatkan kualitas analisis sentimen pada ulasan e-commerce.



Pemisahan Teks Balasan Penjual

Menambahkan tahap preprocessing untuk mendeteksi dan memisahkan teks balasan penjual dari teks ulasan pelanggan. Bisa dilakukan dengan heuristik pattern matching terhadap template balasan, atau dengan menandai elemen DOM yang berbeda saat proses scraping.



Penambahan Volume Data

Memperbesar dataset terutama untuk kelas Netral dan Negatif yang saat ini underrepresented. Scraping dari lebih banyak produk atau toko lain dalam domain kosmetik dapat memberikan sampel yang lebih bervariasi dan meningkatkan kemampuan generalisasi model.



Eksplorasi Teknik Oversampling

Membandingkan pendekatan `class_weight='balanced'` yang digunakan saat ini dengan teknik oversampling seperti SMOTE atau Random Oversampling. Pendekatan berbeda mungkin memberikan trade-off performa yang lebih optimal.



Eksplorasi Model Deep Learning (IndoBERT)

Model transformer seperti IndoBERT yang di-pretrain pada korpus Bahasa Indonesia diharapkan lebih mampu menangkap konteks dan relasi antar kata, mengatasi keterbatasan TF-IDF yang hanya berbasis frekuensi tanpa mempertimbangkan urutan atau makna kontekstual kata.

Terima Kasih

Sesi tanya jawab terbuka untuk diskusi lebih lanjut.

Presentasi oleh
Kelompok 4

Program Studi
Teknik Informatika

Universitas
UIN Syarif Hidayatullah Jakarta

Mata Kuliah Sains Data · Fakultas Sains dan Teknologi